20 · Memasang Model AI Lokal (Ollama / LM Studio)

> **Mulai dari 28 · Menyambungkan Asisten AI**: panduan satu pintu (lokal, cloud gratis, cloud berbayar). Bab ini berisi rincian model lokal: kebutuhan komputer, jaringan kantor, dan masalah umum. Sejak versi 2026.11.10, **semua model yang sudah diunduh terdeteksi otomatis**, jadi nama model tidak perlu disamakan dengan `config\ai.yaml`.

Panduan untuk admin **tanpa latar belakang IT**. Hasil akhirnya: menu **Asisten AI** bisa menjawab pertanyaan, dan **data tidak keluar** dari komputer kantor.

> **Penting:** model AI lokal **tidak** berjalan di Docker dan tidak ikut terpasang oleh `PASANG.cmd`. Model dipasang sendiri di **Windows komputer server yang sama**. Boleh dipasang sebelum, saat, atau sesudah instalasi. Tidak perlu memasang ulang aplikasi.

```
Browser ──► ALDx (di Docker)
                │  host.docker.internal
                ▼
          Ollama :11434   atau   LM Studio :1234   (dipasang sendiri di Windows)
```

1. Pilih salah satu

	Ollama (disarankan)	LM Studio
Tampilan	tanpa jendela, berjalan di tray	aplikasi berjendela, mudah dilihat
Menyala sendiri saat Windows menyala	ya	perlu diatur (§3 langkah 7)
Cara memasang model	satu perintah	klik di menu *Discover*
Alamat untuk ALDx	`http://host.docker.internal:11434/v1`	`http://host.docker.internal:1234/v1`
Terdeteksi otomatis oleh ALDx	ya, semua model yang diunduh	ya, semua model yang diunduh

Kebutuhan komputer (selain jatah Docker):

Model	RAM tambahan	Disk	Kecepatan tanpa GPU
Qwen 2.5 7B (disarankan)	± 6 GB	± 5 GB	10–40 detik per jawaban
Qwen 2.5 14B (lebih pintar)	± 12 GB	± 9 GB	30–90 detik

Total RAM server disarankan **16 GB atau lebih**. Kartu grafis (GPU NVIDIA) membuat jawaban jauh lebih cepat tetapi tidak wajib. Model **wajib mendukung "tool calling"**; Qwen 2.5 dan Llama 3.1 sudah mendukung.

---

2. Cara A: Ollama

1. **Unduh** di komputer server: https://ollama.com/download/windows → jalankan `OllamaSetup.exe` → *Install*. (Dari installer ALDx: halaman **Asisten AI → Unduh Ollama**.)
2. Setelah selesai, ikon llama muncul di tray (pojok kanan bawah). Ollama otomatis menyala setiap Windows menyala.
3. Buka **PowerShell**, unduh model (sekali, ± 4,7 GB, butuh internet): `powershell ollama pull qwen2.5:7b`
4. **Uji** di PowerShell (jawaban muncul dalam beberapa detik): `powershell ollama run qwen2.5:7b "Sebutkan tiga warna primer"` Tekan `Ctrl+D` untuk keluar.
5. **Izinkan Docker menghubungi Ollama** (sekali): Windows → cari *Edit the system environment variables* → **Environment Variables…** → bagian *User variables* → **New…** - Variable name: `OLLAMA_HOST` - Variable value: `0.0.0.0`

OK, lalu klik kanan ikon llama di tray → **Quit Ollama** → buka lagi **Ollama** dari menu Start. Bila Windows Firewall bertanya, pilih **Allow** (jaringan *Private*). 6. Lanjut ke §4 Memeriksa dari ALDx.

3. Cara B: LM Studio

1. **Unduh** di komputer server: https://lmstudio.ai/download → pilih **Windows** → jalankan installer. (Dari installer ALDx: halaman **Asisten AI → Unduh LM Studio**.)
2. Buka **LM Studio**. Klik ikon kaca pembesar **Discover** di kiri.
3. Ketik `qwen2.5 7b instruct` → pilih **Qwen2.5 7B Instruct** (format GGUF, kuantisasi *Q4_K_M*) → **Download** (± 4,7 GB).
4. Klik ikon **Developer** (atau *Local Server*) di kiri → pilih model yang diunduh di atas → aktifkan **Start Server** / status **Running**. Port bawaan **1234**.
5. Di pengaturan server, aktifkan **Serve on Local Network** (agar Docker bisa menghubungi). Bila Windows Firewall bertanya, pilih **Allow**.
6. Nama model tidak perlu disamakan: ALDx membaca daftar model LM Studio secara otomatis.
7. Agar menyala sendiri: LM Studio → **Settings** → aktifkan *Start LM Studio on login* dan *Start server automatically* (nama menu bisa sedikit berbeda antar versi).

3b. Bila jaringan kantor memblokir unduhan model

Gejala: di LM Studio *Discover* kosong / *network error* / *certificate*, atau `ollama pull` gagal. Penyebab: keamanan jaringan kantor (SSL inspection / blokir situs model). Coba berurutan:

Cara 1 — Proxy bawaan LM Studio (paling cepat dicoba). LM Studio → **Settings** (ikon roda gigi) → cari opsi *Use LM Studio's Hugging Face Proxy* → aktifkan → ulangi pencarian model di *Discover*. (Nama opsi bisa sedikit berbeda antar versi; tidak semua jaringan mengizinkan.)

Cara 2 — Unduh berkas model lewat browser, lalu impor (biasanya berhasil, karena browser memakai sertifikat kantor).

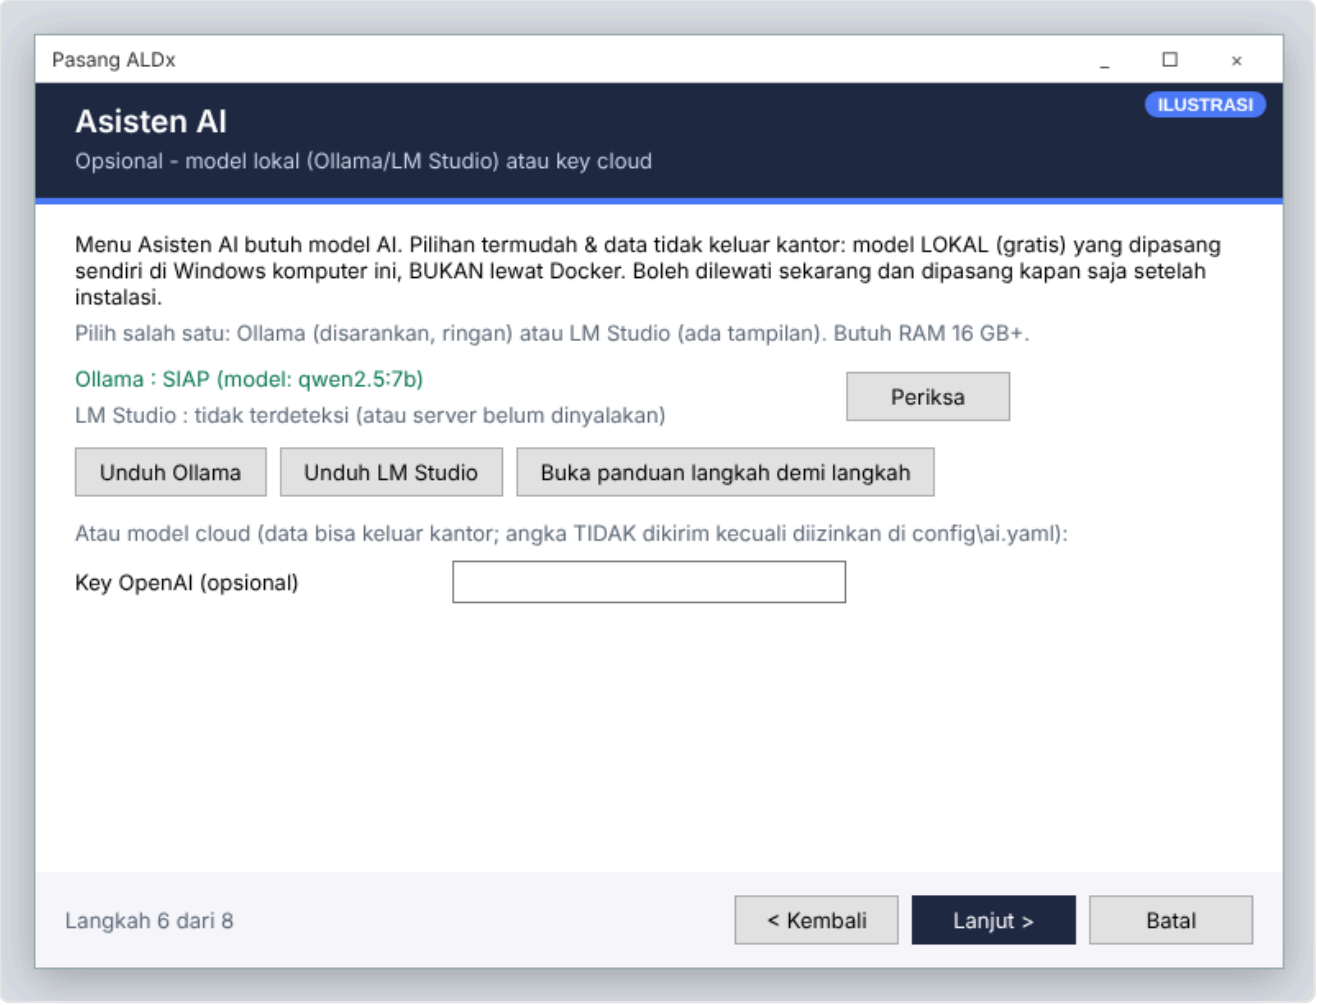
1. Di browser (Chrome/Edge), buka alamat berikut dan tunggu unduhan selesai (± 4,7 GB): `https://huggingface.co/lmstudio-community/Qwen2.5-7B-Instruct-GGUF/resolve/main/Qwen2.5-7B-Instruct-Q4_K_M.gguf`
2. Buat folder (ganti `<nama>` dengan nama pengguna Windows Anda): `C:\Users\<nama>\.lmstudio\models\lmstudio-community\Qwen2.5-7B-Instruct-GGUF\`
3. Pindahkan berkas `Qwen2.5-7B-Instruct-Q4_K_M.gguf` ke folder itu. (Alternatif: PowerShell `lms import "C:\Users\<nama>\Downloads\Qwen2.5-7B-Instruct-Q4_K_M.gguf"`.)
4. Tutup & buka lagi LM Studio → **My Models**: model muncul. Lanjutkan §3 langkah 4–7.
5. Lihat nama model di tab **Developer**; bila berbeda dari `qwen2.5-7b-instruct`, samakan `model:` di `config\ai.yaml`.

Cara 3 — Unduh dari jaringan lain. Unduh berkas `.gguf` di atas dari jaringan rumah/tethering, salin ke server dengan flashdisk/berbagi folder (perhatikan aturan keamanan kantor), lalu ikuti Cara 2 langkah 2–5.

Cara 4 — Minta tim jaringan membuka akses ke `huggingface.co` dan `*.hf.co` (untuk LM Studio) atau `ollama.com` dan `registry.ollama.ai` (untuk Ollama). Hanya dibutuhkan saat mengunduh model; setelah itu model berjalan **tanpa internet**.

> Model cloud (key OpenAI/Gemini) juga terkena aturan jaringan yang sama; bila diblokir, model lokal lewat Cara 2 adalah jalan paling mudah.

4. Memeriksa dari ALDx



Cara	Hasil yang benar
Installer `PASANG.cmd` → halaman **Asisten AI** → **Periksa**	`Ollama : SIAP (model: qwen2.5:7b)` atau `LM Studio : SIAP (...)`
Browser di server: `http://localhost:11434/api/tags` (Ollama) atau `http://localhost:1234/v1/models` (LM Studio)	daftar model dalam teks JSON
Dari dalam container: `docker compose exec superset curl -s http://host.docker.internal:11434/api/tags`	sama seperti di atas
Aplikasi → menu **Asisten AI** → pilih model lokal → tanya *"Dataset apa saja yang tersedia?"*	daftar dataset muncul

Hanya model yang **aktif** yang tampil di pilihan model. Bila belum ada satu pun, panel Asisten AI menampilkan layar **Sambungkan Asisten AI** berisi status tiap aplikasi lokal dan langkah memasangnya. Setelah Ollama/LM Studio dinyalakan, klik **Periksa lagi** (tanpa menunggu, tanpa restart).

5. Masalah umum

Gejala	Penyebab	Solusi
"Model tidak bisa dihubungi" / *connection refused*	Ollama/LM Studio mati, atau hanya menerima dari komputer itu sendiri	nyalakan; Ollama: `OLLAMA_HOST=0.0.0.0` lalu buka ulang; LM Studio: *Serve on Local Network*
Installer: *tidak terdeteksi* padahal sudah dipasang	aplikasi belum dibuka / server LM Studio belum *Start*	buka aplikasinya, klik **Periksa** lagi
"model not found"	model dihapus setelah terdeteksi	klik **Periksa lagi** di layar Sambungkan AI, atau pilih model lain
Jawaban sangat lambat (> 2 menit)	RAM kurang / tanpa GPU	tutup aplikasi lain, pakai model 7B, atau naikkan `batas_detik_lokal` di `ai.yaml`
Permintaan bertahap (gabung dataset, buat dashboard) berhenti *"belum selesai dalam 5 menit"*	tiap langkah model lokal butuh 1–3 menit	pakai model dengan GPU / cloud, atau minta satu hal per pertanyaan
Jawaban ngawur / tidak memakai data	model terlalu kecil / tanpa tool calling	pakai Qwen 2.5 7B ke atas
Komputer jadi berat	model memakai RAM besar	Ollama melepas model setelah ± 5 menit tidak dipakai; LM Studio: *Eject* model
`ollama pull` / LM Studio gagal mengunduh: sertifikat / TLS / *network error*	keamanan jaringan kantor	§3b: unduh `.gguf` lewat browser lalu impor ke LM Studio

6. Keamanan

- Model lokal berjalan di komputer kantor: pertanyaan & angka **tidak dikirim ke internet** (internet hanya dipakai saat mengunduh model).
- Asisten AI selalu bertanya ke data **sebagai pengguna yang login**, jadi hak akses data (RLS) tetap berlaku.
- Model cloud (Gemini, Groq, OpenRouter, Cerebras, Mistral, GitHub Models, Grok, OpenAI, Anthropic) memakai `kirim_data: false` : angka hasil query tidak dikirim ke penyedia kecuali admin mengubahnya dengan izin resmi (10-asisten-ai.md).