28 · Menyambungkan Asisten AI (lokal, cloud gratis, cloud berbayar)

Panduan **satu pintu** untuk menghidupkan Asisten AI: dari memasang model sampai mengisi key. Cukup pilih **satu** jalur. Jalur bisa ditambah atau diganti kapan saja **tanpa memasang ulang dan tanpa restart**.

Jalur	Biaya	Data	Cocok untuk
A. Lokal (Ollama, LM Studio, Jan, llama.cpp)	gratis	**tidak keluar** dari komputer	kantor, data sensitif, tanpa internet
B. Cloud gratis (Gemini, Groq, OpenRouter, Cerebras, Mistral, GitHub Models)	gratis, kuota harian	pertanyaan dikirim ke penyedia; **angka hasil query tidak**	mencoba cepat, komputer kecil
C. Cloud berbayar (OpenAI, Anthropic Claude, xAI Grok, DeepSeek)	per pemakaian	sama seperti B	jawaban paling pintar & cepat

1. Di mana menyambungkannya

Ada empat tempat. Hasilnya sama:

1. **Di aplikasi (termudah):** tekan `Ctrl + I` atau ikon ✦ di kanan atas untuk membuka panel **Asisten AI**. Bila belum ada model, layar **Sambungkan Asisten AI** langsung muncul. Setelah itu, layar ini bisa dibuka kapan saja lewat ikon **sambung** (🔗) di kepala panel. - Tab **Lokal**: status Ollama / LM Studio / Jan / llama.cpp, model yang sudah terdeteksi, dan langkah memasang lengkap dengan tombol **Salin** perintah. - Tab **Cloud gratis** / **Cloud berbayar**: tombol **Buat key ↗**, kolom untuk menempel key, lalu **Simpan**. Sebelum disimpan, key diuji langsung ke penyedianya. Key tersimpan **terenkripsi** di database dan berlaku di semua node. Hanya **Admin** yang bisa mengisi; pengguna lain melihat statusnya saja. - Tombol **Periksa lagi**: deteksi ulang tanpa menunggu.
2. **Di Pusat Kendali › Asisten AI** (Admin; juga menu **Kelola › Asisten AI**): semua isi layar di atas dalam bentuk tabel, ditambah **Uji** (mengirim pertanyaan pendek dan menampilkan waktu jawab) dan **Jadikan bawaan** (model yang dipakai pertama kali oleh semua pengguna).
3. **Di installer:** halaman **Asisten AI** (kini selalu tampil, boleh dilewati) berisi tombol **Periksa**, **Unduh Ollama / LM Studio**, pilihan layanan cloud, dan **? Cara membuat key**.
4. **Di berkas** `.env` (untuk tim TI): `AI_GEMINI_API_KEY=...` dan seterusnya, lalu `docker compose up -d`. Key di `.env` didahulukan daripada key yang diisi lewat aplikasi.

Setiap pengisian dan penghapusan key dicatat di **Pusat Kendali › Riwayat** (kelompok *Asisten AI*).

2. Jalur A: model lokal

Model lokal **tidak** berjalan di Docker. Pasang aplikasinya di **Windows komputer server yang sama** dengan ALDx. ALDx memeriksa alamat berikut setiap 60 detik, dan **semua model chat yang sudah diunduh langsung muncul** di pilihan model. Nama model tidak perlu ditulis di mana pun.

Aplikasi	Port	Diperiksa di alamat
Ollama	11434	`http://host.docker.internal:11434/v1`
LM Studio	1234	`http://host.docker.internal:1234/v1`
Jan	1337	`http://host.docker.internal:1337/v1`
llama.cpp (`llama-server`)	8080	`http://host.docker.internal:8080/v1`

Model embedding (mis. `bge-m3` , `nomic-embed-text`) dilewati secara otomatis karena tidak bisa menjawab pertanyaan.

2.1 Memilih model sesuai RAM

Model harus mendukung **tool calling** (pemanggilan fungsi). Semua contoh di bawah sudah mendukungnya.

RAM komputer	Contoh model (Ollama)	Unduhan	Catatan
8 GB	`qwen3:4b`	± 2,5 GB	cukup untuk tanya data sederhana
16 GB	`qwen3:8b` atau `gpt-oss:20b`	5–13 GB	**disarankan** untuk kantor
32 GB+ / ada GPU NVIDIA	`qwen3:14b` , `qwen3:30b`	9–19 GB	paling pintar untuk analisis

Tanpa GPU, satu jawaban bisa makan waktu 10–90 detik, dan itu normal. Dengan GPU, jauh lebih cepat. Nama model di penyedia bisa berganti; pilih versi *instruct* terbaru dari keluarga yang sama.

2.2 Ollama (disarankan, paling ringan)

1. Unduh: https://ollama.com/download › jalankan `OllamaSetup.exe` › **Install**. Ikon llama muncul di pojok kanan bawah, dan Ollama menyala otomatis setiap Windows menyala.
2. Buka **PowerShell**, unduh model (sekali): `powershell ollama pull qwen3:4b`
3. Di ALDx: panel Asisten AI › **Periksa lagi**. Status Ollama berubah menjadi **siap · 1 model**.
4. Bila tetap *belum menyala* padahal ikon llama ada, izinkan Docker menghubunginya (sekali): Windows › cari *Edit the system environment variables* › **Environment Variables…** › *User variables* › **New…** `OLLAMA_HOST` = `0.0.0.0` › OK › klik kanan ikon llama › **Quit** › buka lagi Ollama. Bila Firewall bertanya, pilih **Allow** (Private).

2.3 LM Studio (ada tampilan, mudah dipantau)

1. Unduh: https://lmstudio.ai/download › pasang › buka.
2. Tab **Discover** (kaca pembesar) › cari `qwen3` › pilih ukuran sesuai RAM › **Download**.

3. Tab **Developer** › pilih model › nyalakan **Start server** (port 1234) dan aktifkan **Serve on Local Network**.
4. Di ALDx: **Periksa lagi**. Bila statusnya *menyala, belum ada model*, muat modelnya di tab Developer.
5. Agar menyala sendiri: Settings › *Start LM Studio on login* + *Start server automatically*.

2.4 Jan

1. Unduh: https://jan.ai/download › pasang › **Hub** › unduh model (mis. Qwen3).
2. **Settings › Local API Server** › **Start** (port 1337) › di ALDx **Periksa lagi**.

2.5 llama.cpp (untuk tim TI)

```
llama-server -m D:\model\qwen3-8b-q4_k_m.gguf --port 8080 --host 0.0.0.0 --jinja
```

`--jinja` wajib agar tool calling aktif.

2.6 Server model di komputer lain (vLLM, Ollama di server GPU)

Tambahkan servernya di `config\ai.yaml` bagian `temukan_lokal` (berlaku tanpa restart):

```
temukan_lokal:
  - nama: Server GPU
    base_url: http://10.1.2.3:8000/v1
```

2.7 Jaringan kantor memblokir unduhan model

Lihat 20 · Model AI lokal §3b: unduh berkas `.gguf` lewat browser lalu impor ke LM Studio. Setelah terunduh, model berjalan **tanpa internet**.

---

3. Jalur B: cloud gratis

Semua layanan ini gratis dengan kuota harian. Langkah umumnya: **daftar › buat key › tempel di ALDx › Simpan**.

Layanan	Halaman key	Langkah singkat	Key diawali
Google Gemini	https://aistudio.google.com/app/apikey	login akun Google › *Create API key*	`AIza`
Groq (sangat cepat)	https://console.groq.com/keys	daftar (tanpa kartu kredit) › *Create API Key*	`gsk_`
OpenRouter	https://openrouter.ai/settings/keys	daftar › *Create Key* (batas kredit boleh 0); ALDx memakai model `:free`	`sk-or-`

Layanan	Halaman key	Langkah singkat	Key diawali
Cerebras (sangat cepat)	https://cloud.cerebras.ai/	daftar › *API Keys* › *Generate*	`csk-`
Mistral	https://console.mistral.ai/api-keys	pilih paket *Experiment* (verifikasi nomor HP) › *Create new key*	—
GitHub Models	https://github.com/settings/personal-access-tokens/new	*Fine-grained token* › Permissions › *Models: Read-only*	`github_pat_`

Perhatikan: di paket gratis, pertanyaan Anda bisa dipakai penyedia untuk melatih modelnya. ALDx **tidak mengirim angka hasil query** ke model cloud (`kirim_data: false`). Yang dikirim hanya pertanyaan serta nama kolom dan tabel.

4. Jalur C: cloud berbayar

Isi saldo di penyedia terlebih dahulu, lalu buat key. Tarif dihitung per pemakaian; cek halaman harga masing-masing penyedia.

Layanan	Halaman key	Catatan	Key diawali
OpenAI (GPT)	https://platform.openai.com/api-keys	isi saldo di *Billing*	`sk-`
Anthropic (Claude)	https://console.anthropic.com/settings/keys	isi saldo di *Billing*	`sk-ant-`
xAI (Grok)	https://console.x.ai/	akun baru biasanya dapat kredit awal	`xai-`
DeepSeek	https://platform.deepseek.com/api_keys	tarif rendah	`sk-`

Gemini juga punya paket berbayar dengan key yang sama: aktifkan *billing* di Google AI Studio bila kuota gratisnya kurang.

5. Mengganti model, menambah layanan, privasi

- **Model yang dipakai pertama kali:** pilih di Pusat Kendali › Asisten AI › **Jadikan bawaan** (atau `bawaan:` di `config\ai.yaml` ; pilihan di Pusat Kendali didahulukan). Bila model itu tidak aktif, model aktif pertama dipakai (urutan: lokal, lalu cloud). Pengguna bisa mengganti model di bawah kotak tanya.
- **Nama model cloud** (mis. `gemini-flash-latest`) diatur di `model:` pada `config\ai.yaml` . Bila muncul *model not found*, ganti namanya sesuai halaman model penyedia. Perubahan berlaku tanpa restart.

- **Layanan lain yang kompatibel OpenAI** (Together, Fireworks, Azure OpenAI, server internal): tambahkan satu blok `model:` dengan `base_url`, `model`, `api_key_env`, `kategori`, dan `url_key`. Layanan itu otomatis muncul di layar Sambungkan AI.
- **Privasi:** `kirim_data: true` hanya untuk model lokal atau layanan yang sudah disetujui resmi.

6. Masalah umum

Gejala	Penyebab	Solusi
Tidak ada ikon ✦ sama sekali	akun tidak punya akses Asisten AI	Admin: jalankan `scripts\build-dashboards.ps1` (memberi izin ke role Admin, Superadmin, dan role pengguna)
Status *belum menyala* padahal aplikasinya terbuka	server lokal hanya menerima dari komputer itu sendiri	Ollama: `OLLAMA_HOST=0.0.0.0`; LM Studio: *Serve on Local Network*; izinkan di Firewall
menyala, belum ada model	belum ada model yang diunduh/dimuat	`ollama pull qwen3:4b` atau unduh/muat di LM Studio
Key ditolak penyedia (401/403)	key salah salin / sudah dicabut	buat key baru, tempel ulang tanpa spasi
Penyedia tidak bisa dihubungi dari server	tidak ada internet / proxy kantor / SSL inspection	taruh sertifikat CA kantor di `certs\`, isi `AI_CA_BUNDLE` di `.env` (certs/README); atau pakai jalur lokal
Key yang diisi lewat aplikasi tidak terbaca setelah pindah server	`SUPERSET_SECRET_KEY` berbeda	isi ulang key di layar Sambungkan AI
Jawaban lambat / ngawur	model terlalu kecil untuk pertanyaannya	pakai model lebih besar (§2.1) atau layanan cloud
"terlalu lama menjawab"	model lokal di CPU melewati batas waktu satu langkah	naikkan `batas_detik_lokal` (bawaan 240 dtk) di `config\ai.yaml`; cloud memakai `batas_detik_model` (120 dtk)
"Server '…' sedang sibuk atau bermasalah (HTTP 503…)"	penyedia (mis. Gemini gratis) kelebihan beban	ALDx sudah mencoba ulang 2×. Tambahkan model kedua (key gratis lain atau model lokal) agar ALDx otomatis beralih; atau coba lagi beberapa menit kemudian
"Kuota/batas permintaan … habis" (429)	batas harian/menit paket gratis	tunggu, pakai model lain, atau paket berbayar
"Nama model … tidak dikenali" (404)	penyedia mengganti nama model	perbarui `model:` di `config\ai.yaml` sesuai halaman model penyedia
"belum selesai dalam 15 menit"	permintaan butuh banyak langkah dan model terlalu lambat	pakai model lebih kuat (cloud, atau lokal dengan GPU), pecah permintaan, atau naikkan `batas_latar_detik` di `config\ai.yaml`

Gejala	Penyebab	Solusi
"Server memutus permintaan…"	instalasi tanpa Redis (mode latar mati), batas ±5 menit	pastikan layanan `redis` berjalan (`docker compose ps`)